

CONTEXT

ตัวอย่างคำถาม

LEVEL 1 : SINGLE CATEGORIES

Rainbow Group: Construction-Related

Category: Repair Method

Question: เกณฑ์การซ่อมแซมรอยร้าวสำหรับรอยร้าวแบบ Hard Crack คืออะไร

Answer: ต้องมีความกว้างของรอยร้าว (A) มากกว่า 0.1 มม. แต่ไม่น้อยกว่า 0.3 มม. ($0.1 < A < 0.3$) และมีความลึกมากกว่า 15 มม.

Page : 3

LEVEL 2 : MULTIPLE CATEGORIES

Rainbow Group: Construction-Related

Category: Repair Method / Material / Environmental

Question: ในการซ่อมแซมรูฟองอากาศ (Voids) ที่มีขนาดความกว้าง 5 มม. และลึก 5 มม. โดยใช้วัสดุ Sika Skim Coat ผู้ปฏิบัติงานต้องปฏิบัติตามมาตรการป้องกันผลกระทบต่อสิ่งแวดล้อมด้านคุณภาพน้ำสำหรับวัสดุประเภทนี้อย่างไร


Answer:

1. การเลือกวิธีซ่อม: รูฟองอากาศขนาดกว้างและลึก ≤ 10 มม. ให้ซ่อมด้วย Cementitious Mortar (RP-TN-04)

2. มาตรการสิ่งแวดล้อม (สำหรับวัสดุซ่อมแบบผง – Sika Skim Coat):

- – ปิดทางระบายท่อน้ำทิ้ง แล้วกำจัดน้ำที่ปนเปื้อนในท่อระบายออก
- – ห้ามทิ้งน้ำที่ปนเปื้อนลงพื้นดินโดยเด็ดขาด
- – แบ่งพื้นที่สำหรับงานซ่อมแซม ห้ามใช้วัสดุซ่อมนอกพื้นที่ที่จัดเตรียมไว้
- – หากบรรจุภัณฑ์ฉีกขาด ให้เปลี่ยนบรรจุภัณฑ์ใหม่ หรือภาชนะที่ปิดมิดชิดได้

Page : 6, 8, 135



3.EXPERIMENT DESIGN

3.1 SEMANTIC SIMILARITY RETRIVEVAL (DATABASE EVALUATION)

3.2 LLM PERFORMANCE

3.EXPERIMENT DESIGN

3.1 SEMANTIC SIMILARITY RETRIVEVAL

$$\text{Cosine Similarity}(\mathbf{A}, \mathbf{B}) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|}$$

Context Precision measures the proportion of retrieved content that is actually relevant to the query, while Context Recall assesses the extent to which the system covers all the relevant content necessary to answer the query. They are formally defined as:

$$\text{Context Precision} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}}$$

$$\text{Context Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

where:

- **True positives:** Text segments in the retrieved documents that contain correct and relevant information with respect to the expected answer.
- **False positives:** Text segments in the retrieved documents that do not contribute relevant information to the answer.
- **False negatives:** Relevant content that would have been necessary for a complete answer but was not retrieved.

3.EXPERIMENT DESIGN

3.2 LLM PERFORMANCE : POLRAG: A RAG-LLM FRAMEWORK FOR POLICY QUESTION ANSWERING

Evaluation Metrics	Scoring Standards	Score range
Accuracy	10 points: Complete citation of policy basis, and the answer content is fully consistent with the current policy. 8–9 points: There are minor omissions, but they do not affect the core content. 6–7 points: Key information is missing or there are errors in citation. 0–5 points: The answer is wrong or there is no policy basis.	0–10 points
Completeness	10 points: Fully cover the key elements of the problem, and the descriptions of multiple situations are complete. 8–9 points: Missing secondary elements. 6–7 points: Key elements are missing. 0–5 points: The core problem is not answered.	0–10 points
Normativeness	10 points: Government affairs terms are accurate, and the format is clear and standardized. 8–9 points: There are a small number of expression or format flaws. 6–7 points: Ambiguous expressions or chaotic format. 0–5 points: Expression errors or no format.	0–10 points

3.EXPERIMENT DESIGN

3.2 LLM PERFORMANCE : POLRAG: A RAG-LLM FRAMEWORK FOR POLICY QUESTION ANSWERING

Evaluation Metrics	Scoring Standards	Score range
Accuracy	10 points: Complete citation of policy basis, and the answer content is fully consistent with the current policy. 8-9 points: There are minor omissions, but they do not affect the core content. 6-7 points: Key information is missing or there are errors in citation. 0-5 points: The answer is wrong or there is no policy basis.	0-10 points
Completeness	10 points: Fully cover the key elements of the problem, and the descriptions of multiple situations are complete. 8-9 points: Missing secondary elements. 6-7 points: Key elements are missing. 0-5 points: The core problem is not answered.	0-10 points
Normativeness	10 points: Government affairs terms are accurate, and the format is clear and standardized. 8-9 points: There are a small number of expression or format flaws. 6-7 points: Ambiguous expressions or chaotic format. 0-5 points: Expression errors or no format.	0-10 points



Evaluation Dimension	Description	Metric / Method	Score
1. Engineering Answer Correctness	ความถูกต้องของคำตอบตามวิธีซ่อมในคู่มือ	Expert validation, rule matching	40
2. Document Grounding Accuracy	ความสามารถในการตอบโดยอิงเอกสารใน database	Citation correctness, hallucination rate	30
3. Bilingual Capability (TH-EN)	รองรับภาษาไทยและอังกฤษอย่างถูกต้อง	Translation accuracy, semantic consistency	10
4. Response Latency	ระยะเวลาตอบคำถาม	Average response time (seconds)	10
5. System Prompt Compliance	ปฏิบัติตาม system prompt และข้อจำกัด	Prompt adherence score	10
Total			100

3.EXPERIMENT DESIGN

1.ENGINEERING ANSWER CORRECTNESS

ระดับคะแนน	คะแนน	เกณฑ์การประเมิน
Excellent	36–40	ระบุวิธีซ่อมถูกต้องตรงตาม Method Statement (เช่น RP-TN-01, RP-TN-02, Reject) พร้อม เงื่อนไขตัวเลขครบถ้วน (crack width, depth, void size ฯลฯ)
Good	26–35	วิธีซ่อมถูกต้อง แต่ขาดรายละเอียดเชิงตัวเลขหรือเงื่อนไขบางส่วน
Fair	16–25	แนวคิดว่าซ่อมถูกบางส่วน แต่เลือกวิธีไม่ตรง guideline
Poor	0–15	วิธีซ่อมผิด หรือขัดแย้งกับเอกสารอย่างชัดเจน

3.EXPERIMENT DESIGN

2. DOCUMENT GROUNDING ACCURACY

ระดับคะแนน	คะแนน	เกณฑ์การประเมิน
Excellent	26–30	คำตอบทั้งหมดอิงจากข้อมูลในเอกสาร ไม่มี hallucination และสอดคล้องกับเนื้อหาใน database
Good	18–25	อ้างอิงเอกสารถูกต้องเป็นส่วนใหญ่ มีการสรุปเกินเอกสารเล็กน้อย
Poor	0–17	มี hallucination ชัดเจน หรือให้ข้อมูลที่ไม่มีในเอกสาร

3.EXPERIMENT DESIGN

3. BILINGUAL CAPABILITY

ระดับคะแนน	คะแนน	เกณฑ์การประเมิน
Excellent	8–10	แปลและตอบได้ถูกต้อง ความหมายตรงกัน ใช้ศัพท์เทคนิค วิศวกรรมถูกต้อง
Good	4–7	ความหมายโดยรวมถูกต้อง แต่มีศัพท์เทคนิคคลาดเคลื่อน
Poor	0–3	ความหมายผิดหรือสื่อสารไม่ชัดเจน

3.EXPERIMENT DESIGN

4. RESPONSE LATENCY

เวลาเฉลี่ยต่อคำถาม	คะแนน
≤ 5 วินาที	10
6–10 วินาที	8
11–20 วินาที	5
> 20 วินาที	0

3.EXPERIMENT DESIGN

5. SYSTEM PROMPT COMPLIANCE

ระดับคะแนน	คะแนน	เกณฑ์การประเมิน
Excellent	8-10	ปฏิบัติตาม system prompt ครบถ้วน (ไม่เดา, ตอบเฉพาะข้อมูลใน database, ปฏิเสธคำถามนอก scope)
Good	4-7	หลุดจาก system prompt บางกรณี แต่ไม่ร้ายแรง
Poor	0-3	ละเมิด system prompt บ่อย หรือให้ข้อมูลนอกขอบเขต